

LG imers 이론 학습 - ML 개론

1. Introduction to ML

- 인공지능의 한 분야, Data로 부터 스스로 개선되는 알고리즘을 설계하는 분야
- 기계 학습의 가장 큰 맹점은 '일반화'
- 하나의 최적 알고리즘이 모든 태스크에 항상 최적인 것은 아니다.
- 학습데이터 전체에 대해 라벨링을 하기 힘들때는 semi-supervised learning으로 데이터 중 일부만 라벨링 되어있고, 라벨링 되어있지 않은 데이터를 섞어서 사용해도 무방하다.
- semi-supervised learning의 종류 : LU learning은 모든 클래스에 대해 일부만 라벨링 하는 것, PU learning은 긍정 샘플에 대해서만 제공하고, 부정 샘플에 대해서는 라벨링하지 않는 것
- semi-supervised learning이 효과적인 이유?
 - > labeling이 되어 있지 않더라도 확률적인 클래스를 추론할 수 있고, 이를 기반으로 조금 더 정확한 decision boundary를 예측할 수 있음
- reinforcement learning
 - > 환경과의 상호작용, 각 state를 평가하고 보상을 주는 과정을 반복, 그 보상을 학습, 강화학습은 state만 변화하고, action에 대한 보상이 delay되어서 이후에 주어지는 경우가 많기 때문에 action에 reward를 평가하기 어려운 경우가 많기때문에 어려움.

2. Bias and Variance

- 각 data point에서의 loss 값의 합을 최소화 하는 모델 파라미터와 편향을 찾자.
- Underfitting : Generalization error < Training error
- Overfitting : Generalization error > Training error
- 적어도 Underfitting은 나지 말아야 한다. -> Overfitting을 최대한 내고 과도한 overfitting이 난다면, train error를 손해보면서 validation, test error를 낮추기.

- 모델 capacity가 커질수록 무조건 training error는 줄지만, 일반화 error는 측정이 불가능하고 예측만 가능하기 때문에 적절 모델 용량을 정하는 것이 중요함.
- 정규화의 목적 : 최적화 문제를 풀 때 목적함수를 설계하는데, training loss만 계산하면 안되기 때문에 과적합 방지, 보완의 차원에서 정규화 term 추가 -> 일반화 error 계산
- Test error : bias + variance(bias는 예측값 평균과 정답과의 차이, variance는 분산을 의미)
- Bias와 variance의 trade-off 관계 -> 둘 다를 보완할 수 있는 방법이 앙상블 러닝

3. Recent Progress of Large Language Models

- GPT3 : PI 형태로 C LL하고 토큰별 과금을 하는 식으로 엔진을 사용할 수 있음.
- InstructGPT : RLHF(사람의 피드백을 통한 강화 학습), 처음에는 지도학습을 하다가, 점차 응답 후보군 생성 후 사람이 더 선호하는 방식으로 학습이 진행된다.
- Multimodal : 정보 형식의 결합, GPT4(이미지, 텍스트)
- 프롬프트 엔지니어링이 중요해졌다.